Fundamentos de Machine Learning

Índice

Introducción	01
ML vs AI	02
Historia	03
Sistemas de Machine Learning: Supervisado no supervisado	04
Librerías	05
Usos	06
Fase de un Proyectos de ML	07

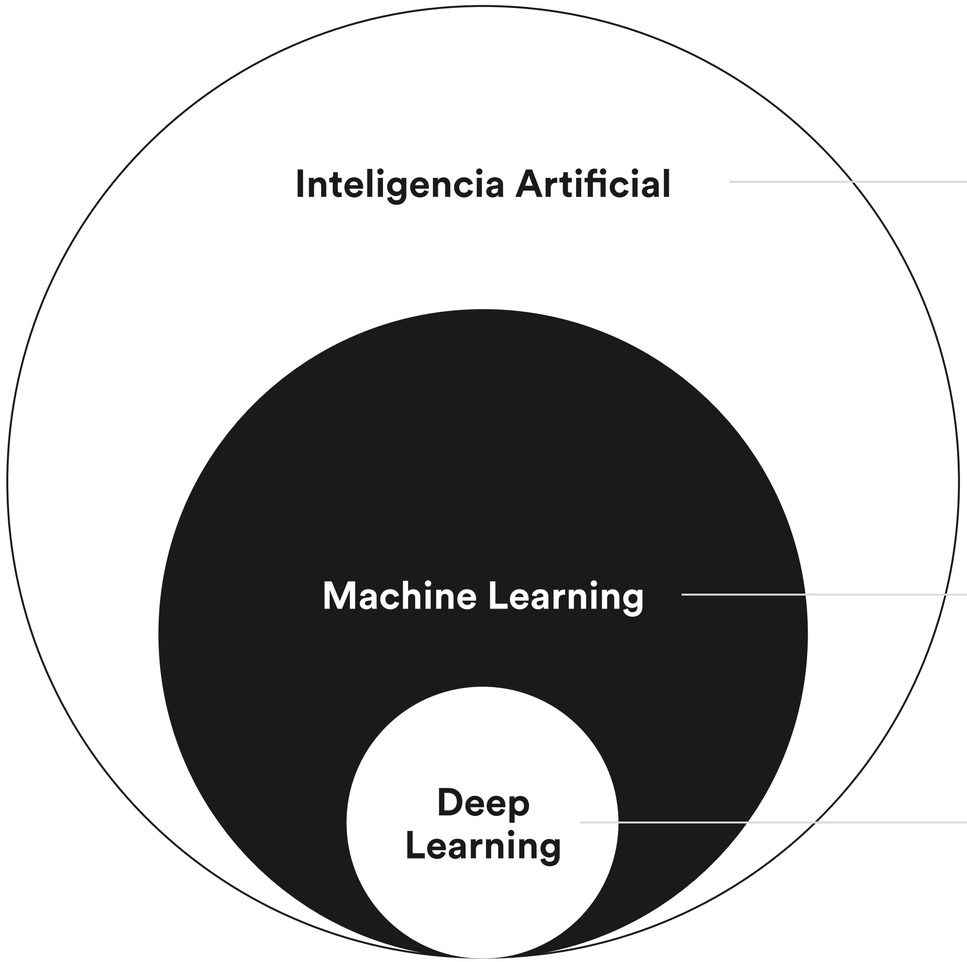
Introduccion: ¿Qué es el Machine Learning?

- “Es la ciencia (o el arte) de programar computadoras para que aprendan de los datos”

- “Es el campo de estudio que da a las computadoras la capacidad de aprender sin haber sido explícitamente programadas”. (Arthur L. Samuel 1957)

- “Se dice que un programa de computadora aprende de la experiencia E con respecto a alguna clase de tareas T y medida de desempeño P si su desempeño en tareas en T, medido por P, mejora con la experiencia E".

Machine Learning vs Artificial Intelligence vs Deep Learning



Técnica que hace que las máquinas imiten el comportamiento humano

Subconjunto de técnica de IA que posibilita que las máquinas mejoren con la experiencia

Subconjunto de técnicas de ML basada en de redes neuronales multicapa.

Machine Learning vs Artificial Intelligence vs Deep Learning

1

Artificial Intelligence

La IA abarca el amplio campo de la creación de máquinas que pueden realizar tareas que requieren inteligencia similar a la humana.

Su objetivo es simular funciones cognitivas humanas, como el aprendizaje, el razonamiento, la resolución de problemas, la percepción y la comprensión del lenguaje natural.

Los sistemas de IA pueden estar basados en reglas (programados explícitamente) o aprender a partir de datos (Machine Learning).

2

Machine Learning

El Machine Learning (ML) es un subconjunto de la IA que se centra en permitir que las máquinas aprendan de los datos y mejoren su rendimiento con el tiempo sin ser programadas explícitamente.

Implica algoritmos que aprenden patrones y hacen predicciones o toman decisiones basadas en los datos de entrada.

Los algoritmos de ML pueden clasificarse en aprendizaje supervisado, aprendizaje no supervisado, aprendizaje semi-supervisado y aprendizaje por refuerzo (Reinforcement Learning)

3

Deep Learning

El Deep Learning (DL) es un subconjunto del ML que utiliza redes neuronales artificiales con múltiples capas (de ahí lo de “deep”) para aprender representaciones de los datos.

Ha ganado importancia debido a su capacidad para descubrir y extraer automáticamente características de los datos en bruto, eliminando la necesidad de ingeniería de características manual.

El DL funciona bien con tareas como el reconocimiento de imágenes, el reconocimiento de voz, el procesamiento del lenguaje natural o la conducción autónoma.

Un poco de historia

Regresión Lineal
En 1800 Gauss inventa la regresion lineal

Mark I
1944 IBM/Harvard crean el primer computador

Invención de la red neuronal
En 1958 Frank Rosenblatt inventa la primera red neuronal

Space Odyssey
En 1968 aparece la película Odisea en el espacio donde se atribuyen capacidades humanas a una computadora

TF-IDF
En los años 70 se crea este algoritmo ampliamente utilizado en NLP

Convolutional Neural Networks
A final de los 80 Yan LeCun introduce las Convolutional Neural Networks empleadas para leer códigos postales de sobres

Reinforcement Learning
1989 se inventa el Reinforcement Learning (Q-Learning)

Random Forest
1995 el chino Tin Kam Ho crea el algoritmo Random Forest

Deep Learning
2006 Se emplea el concepto Deep Learning por primera vez

Siglo XIX → Siglo XX → Siglo XXI

Primera calculadora
En 1820 Charles Babbage crea la primera calculadora

Dartmouth workshop
En 1956 10 de los matemáticos más brillantes dle mundo se reunieron para hablar de IA.

Primeros Algoritmos
Durante los años 60 se formulan los primeros algoritmos: Decision Trees and Nearest Neighbors

Data Science
En 1974 el danés Peter NAur emplea por primera vez el término “Data Science”

Next-talk
En 1985 surgen los primeros experimentos Speech to text

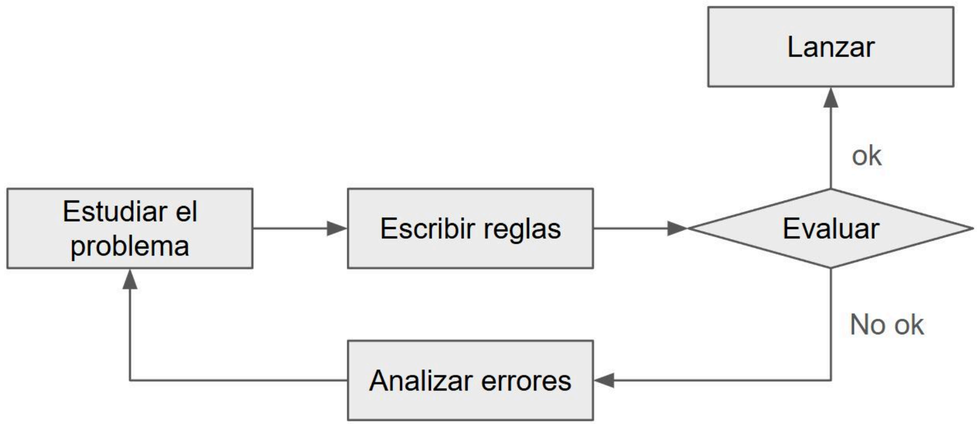
Python
En 1991 Guido Van Rossum crea Python

Support Vector Machine
1992 Vladimir Vapnik desarrolla la teoría de SPM

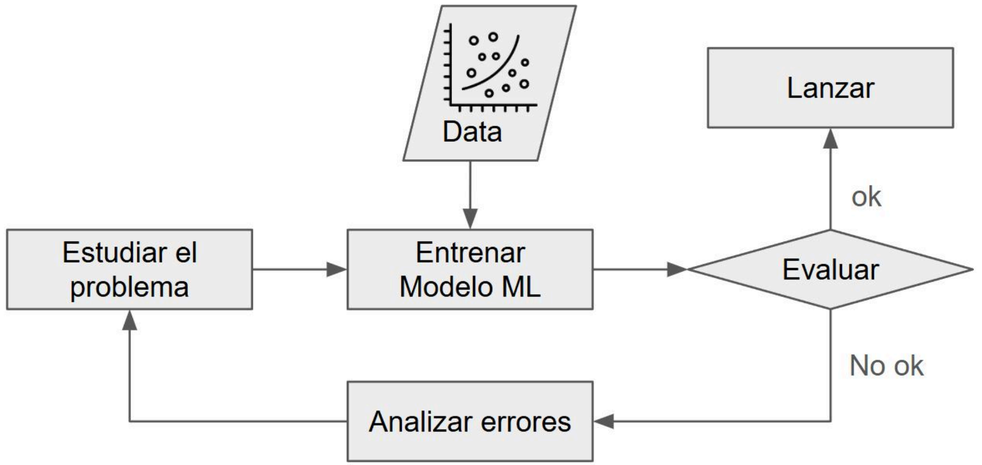
Torch
2002 Aparece Torch la primera libreria open source para ML

Kaggle
2010 Lanzamiento de Kaggle

Ejemplo: Sistema de clasificación de transacciones

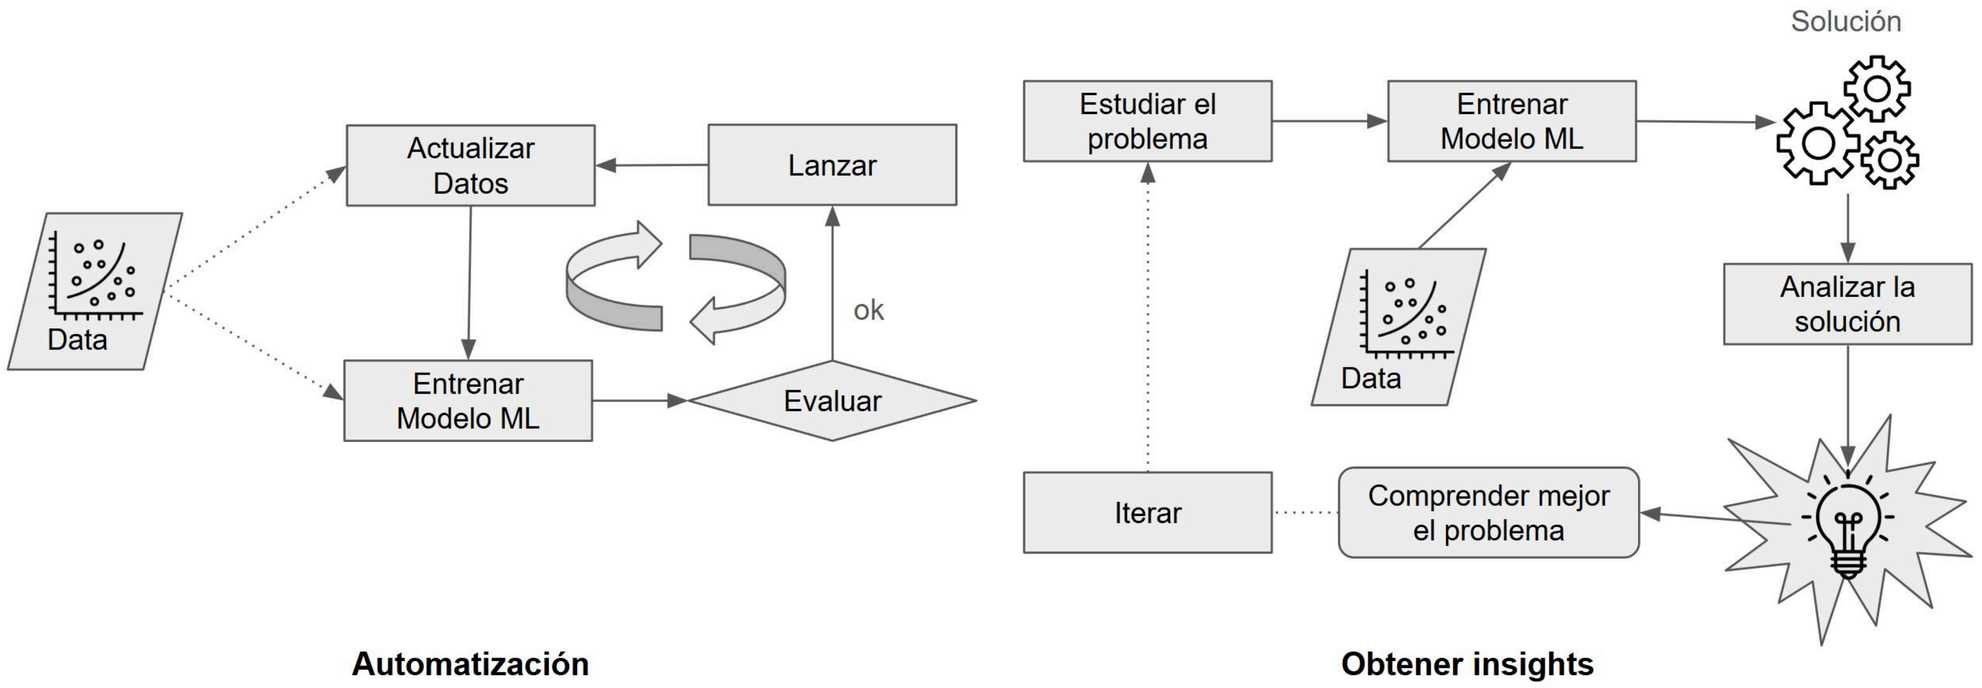


Enfoque tradicional



Enfoque ML

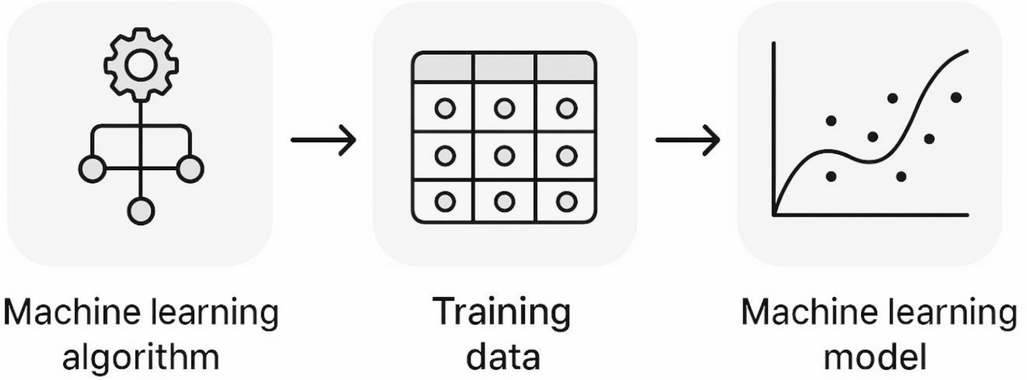
Ejemplo: Sistema de clasificación de transacciones



¿Qué es un modelo?

Definición:

Un modelo de Machine Learning es una representación matemática de un proceso del mundo real. Un algoritmo de aprendizaje automático, junto con los datos de entrenamiento, constituye dicho modelo.



Tipo de sistemas de Machine Learning

1. **Supervisado**

   Para los datos que alimentan el algoritmo tenemos datos etiquetados: etiqueta. Ej.: clasificación de correo spam

2. **No supervisado**

   No disponemos de datos etiquetados. Identifica patrones ocultos en los datos. Ej.: Segmentación de clientes

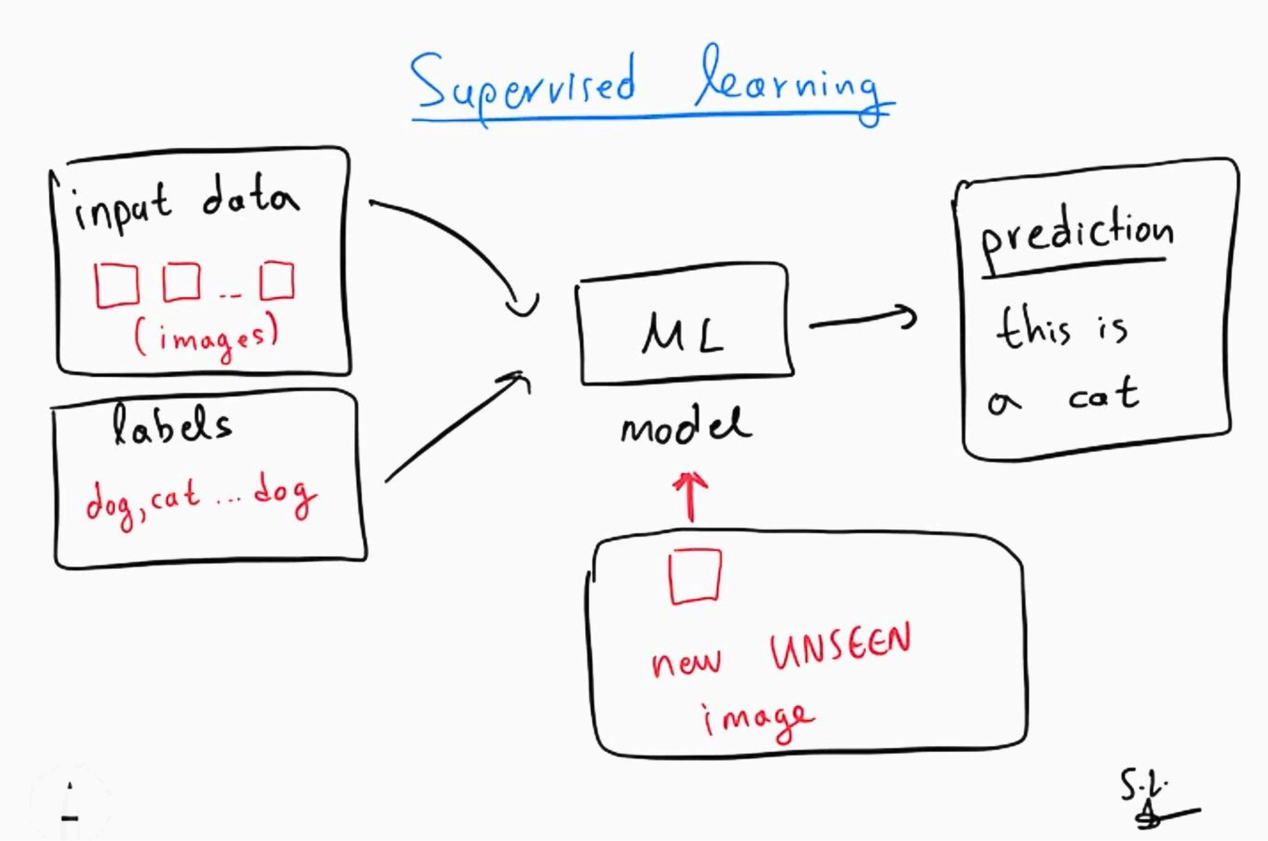
3. **Semi-supervisado**

   Disponemos de etiqueta pero sólo para muy pocos registros. Ej. etiquetar personas en google photos

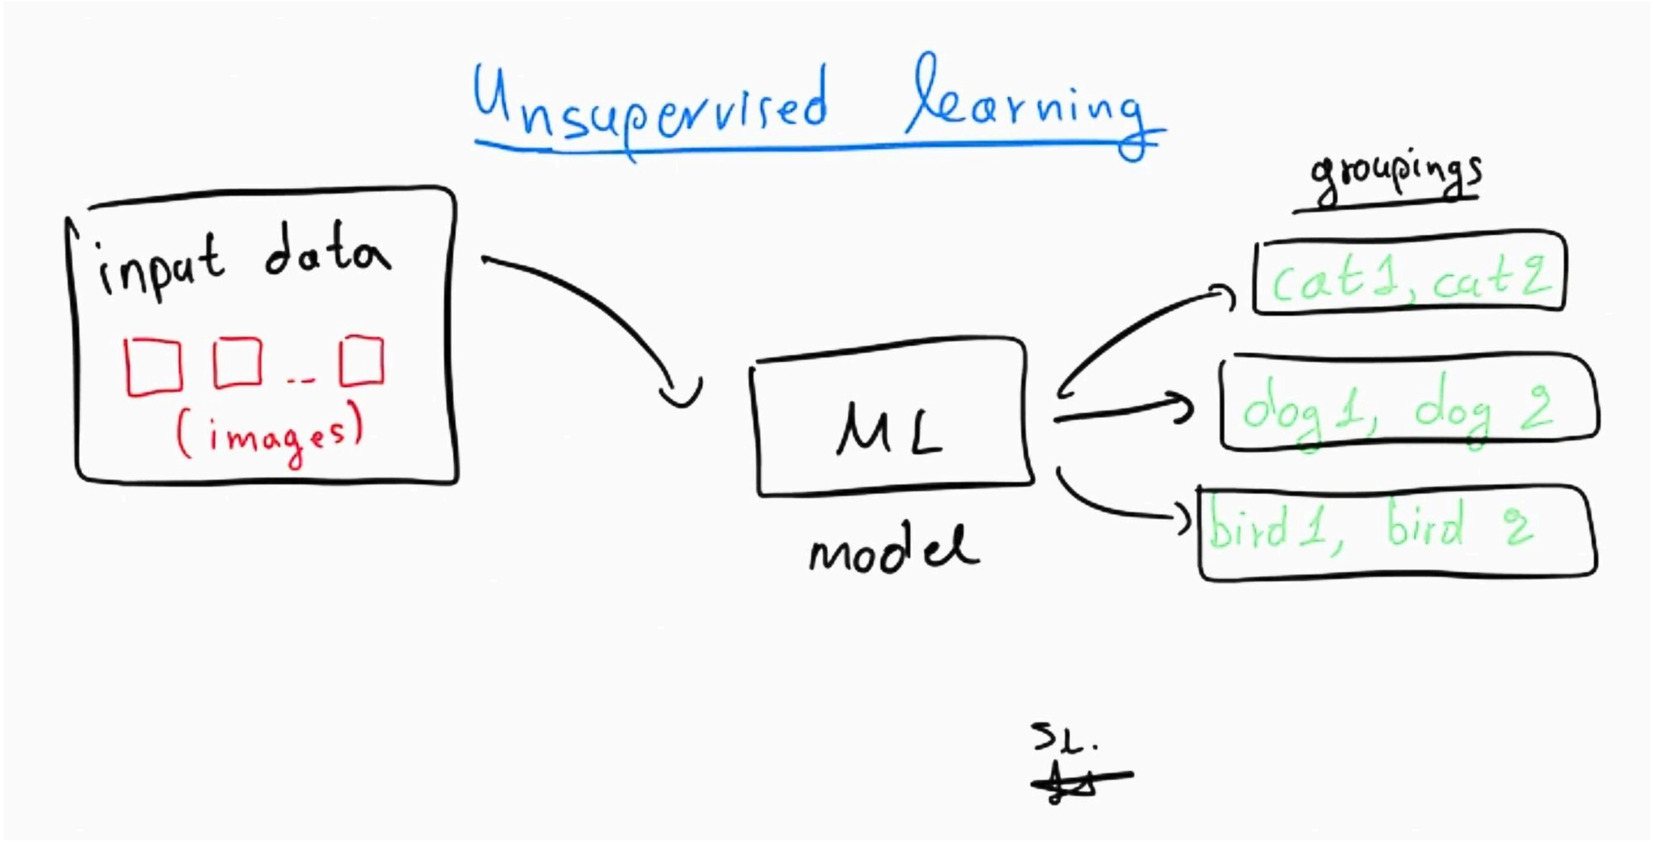
4. **Reinforcement Learning**

   Un agente aprende a tomar decisiones mediante prueba y error, recibiendo recompensas o penalizaciones según sus acciones. El objetivo del agente es maximizar la recompensa acumulada a lo largo del tiempo, desarrollando estrategias óptimas basadas en su experiencia.

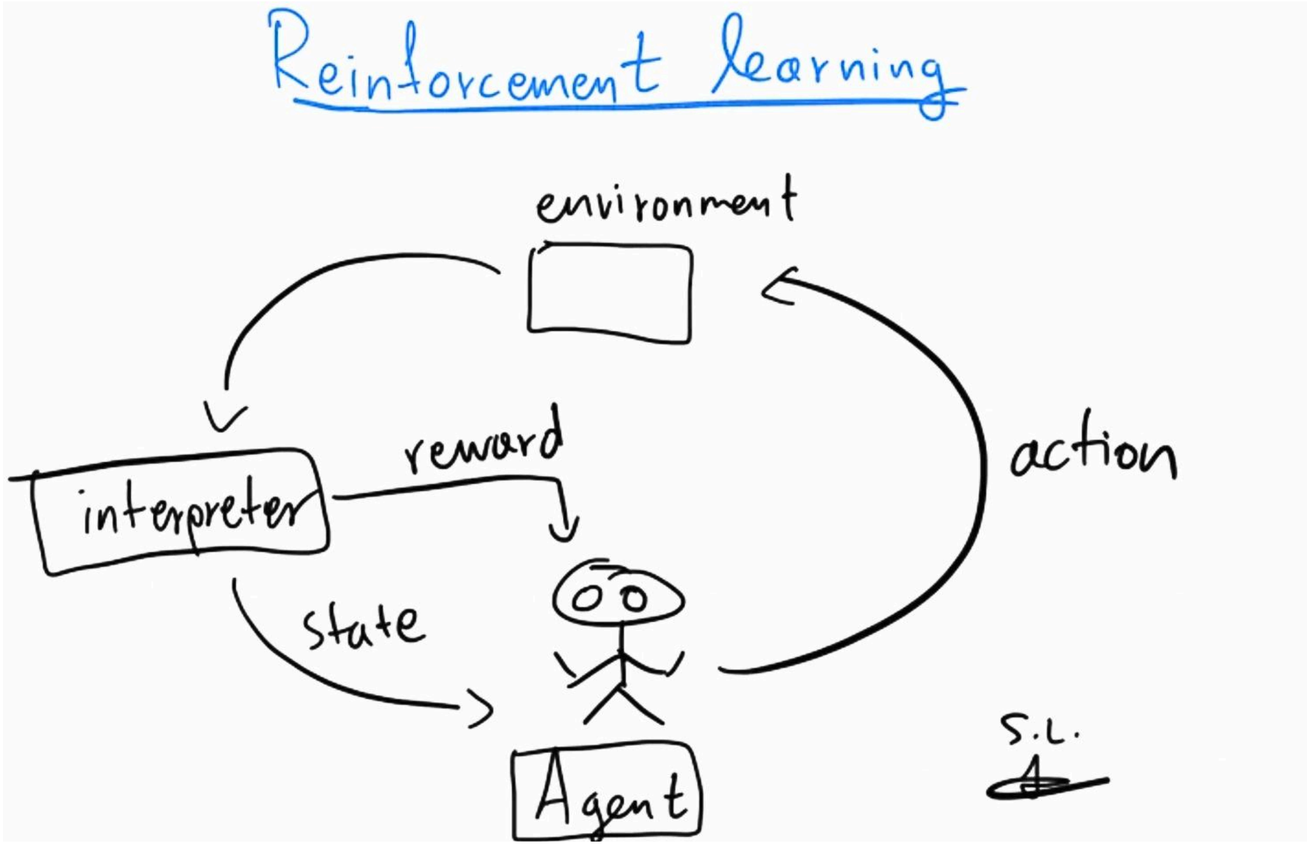
Sistema supervisado



Sistema no supervisado



Reinforcement Learning



Tipo de sistemas de Machine Learning

Algoritmos ML

Supervisados

- Regresion Lineal
- Series Temporales
- Regresión Logistica
- Arboles de decision
- Random Forest
- Support Vector Machine
- Redes Neuronales
- KNN

No Supervisados

- Clustering
- Hierarchical Clustering
- Reglas de asociación
- Componentes Principales (PCA)
- Anomaly detection

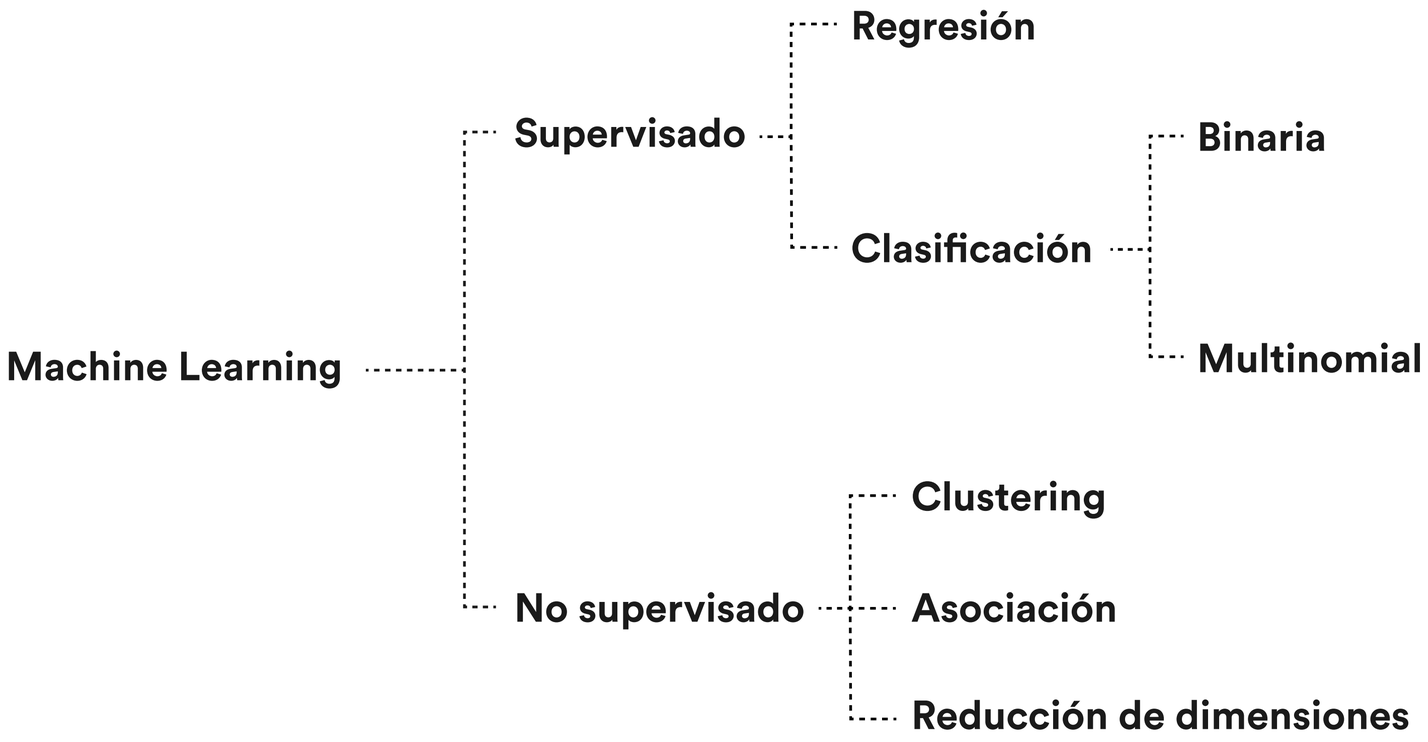
Semi-Supervisados

- Deep Belief Networks(DBM)
- Restricted Boltzman Machines (RBM)

Reinforcement Learning

- Q-Learning:
- Deep Q-Networks (DQN):
- Policy Gradient Methods.

Tipos de problemas



Librerías Python

- Scikit-Learn
- Pandas
- Numpy
- NLTK → tratamiento de texto
- Statsmodels, Pmdarima, prophet → series temporales
- Matplot lib, Seaborn → visualización
- Mlextend → extension de Scikitlearn
- Lightgbm, catboost, xgboost → modelos esemble
- Surprise → sistemas de recomendación
- Tensor Flow, keras → deep learning

Que tipo de problemas resuelven en una organización?

Supervisado

- Modelos predictivos de comportamiento
- Next Best offer
- Modelos de Churn
- Modelos de Upgrade
- Modelos de Upsell / X-sell
- Modelos de targeting
- Estimación de mercados potenciales
- Deteccion de fraudes
- Sistemas de recomendación
- Reconocimiento de imágenes
- P&L forecasts
- Elasticidad al precio
- Lead scoring
- Credit scoring
- Wealth Indicator
- Clasificación del correo electrónico
- Prevision de series temporales

No supervisado

- Segmentaciones de clientes
- Segmentación de municipios
- Detección de anomalías
- Sistemas de recomendación
- Análisis de sendas de vinculación/ desvinculación (reglas de asociación)
- Análisis del sentimiento
- Creación de indicadores: transaccionalidad / sofisticacion (PCA)

Fases de un proyecto ML

Defínción del problema

- Entender el problema de negocio y el uso que se pretende dar a nuestra solución.
- ¿Cual es la variable objetivo?
- ¿Qué variables son susceptibles de ser empleadas.
- ¿Cómo vamos a evaluar nuestro modelo?
- ¿Cómo va a ser consumido?

Consigue los datos

- identifica los datos que necesitas.
- Cuantos datos
- Chequea si hay información sensible. (anonimizar/borrar)
- Construimos el set de variables

Análisis de variables (EDA)

- Identificar tipologías de variables.
- Nivel de información de las variables.
- Distribución de variables.
- Visualización
- Correlación entre ellas.
- Correlación con la variable objetivo.
- Concentración de la variable objetivo

Transformación de variables

- Trabaja con una copia de lo datos
- Limpieza de datos: elimina registros vacio / rellenar
- Selección de variables: excluir variables poco informadas constantes, correladas, ...
- Ingeniería de Variables: categóricas convertirlas en numericas, Discretización
- Estandarización y Normalizar

Modelado

- Balanceo de la muestra
- Separamos nuestra muestra en training y test
- Entrenamos nuestro modelo con parámetros estándar
- Compara el performance de los modelos
- Analiza las variables más significativas para cada modelos
- Revsa los errores

Finetuning

- Optimización de hiperparámetros
- Valora construir un modelo combinado

Presentar el modelo

- Documenta lo que has hecho
- Crea una presentación
- Muestra por qué la solución resuelve el problema de negocio
- Hipótesis asumidas
- Resultados interesantes

¿Dónde encontrar data sets?

1. **Kaggle**

   Kaggle es una plataforma donde se lanzan competiciones y donde se pueden encontrar una gran variedad de datasets para diferentes tipos de proyectos de ML.

   https://www.kaggle.com/

2. **GitHub**

   Hay muchos repositorios en GitHub donde los usuarios además de proyectos, comparten datasets que han creado o recopilado.

   https://github.com/

3. **UC Irvine Machine Learning Repository**

   Este repositorio ofrece una amplia colección de datasets para proyectos de aprendizaje automático y análisis de datos.

   https://archive.ics.uci.edu/datasets

4. **Hugging face**

   Es una plataforma que ofrece una amplia colección de conjuntos de datos y modelos listos para ser usados en proyectos de ML.

   https://huggingface.co/datasets

5. **OpenML**

   OpenML es una plataforma abierta que permite compartir y reutilizar datasets y experimentos de machine learning para fomentar la colaboración y la investigación reproducible.

   https://www.openml.org/